

Relatório — Implementador de IA & Automações

Projeto Revelatio · Avaliação de ferramentas e recomendação de arquitetura para extração de dossiês do Banco X

Data: 2026-05-12

Sumário executivo

Avaliamos nove ferramentas em quatro categorias arquiteturais — workflows comerciais, workflows OSS, LLMs *frontier* e OCR/extração estruturada — buscando uma solução para extrair ~10.000 PDFs de clientes devedores do Banco X em planilha Excel. **Construímos um pipeline de referência em Python** (`06_reference_script/`) que implementa a arquitetura recomendada e medimos **100% de acurácia, zero alucinações e US\$ 0,00934 por dossiê** em validação contra quatro PDFs — três do corpus de base (PDF do brief + F02 + F07) e um *holdout* fora da distribuição que geramos especialmente para este teste (`F09_brief_shape`, mesma estrutura visual do PDF do brief, com dados de cliente completamente novos). **Expusemos esse motor publicamente em <https://revelatio-demo.streamlit.app>**, com gravação automática em planilha Google compartilhada como destino opcional, para que o painel avaliador possa exercitá-lo diretamente. **Recomendamos esse pipeline como caminho principal**, em arquitetura híbrida de duas camadas com regras de *cross-validation* e fila HITL; o Power Automate com AI Builder, que avaliamos *hands-on* e que obteve 92,8% médio em corpus sintético com zero alucinações, fica como **caminho alternativo** para escritórios já residentes em Microsoft 365 que prefiram manutenção *no-code* por paralegal. O custo total estimado para processar o *backlog* de 10.000 dossiês é de **R\$ 457** (PTAX 4,8999, 2026-05-08) contra **R\$ 50.500** do trabalho manual no ponto médio salarial — razão de **~110×** e *payback* no primeiro dia de operação. As conclusões abaixo derivam de testes empíricos cujos artefatos estão referenciados em cada afirmação quantitativa.

§1 — Ferramentas testadas

Avaliamos nove ferramentas, das quais seis em testes *hands-on* e três em estudo analítico (dossiês comparativos). A tabela abaixo consolida os resultados sobre o PDF de exemplo do brief; o Power Automate foi adicionalmente avaliado contra o corpus sintético de oito *fixtures* (F01–F08), e o pipeline de referência em Python foi adicionalmente validado contra o *holdout* OOD `F09_brief_shape` (descrito em §2). A fonte dos números é `04_experiments/SCOREBOARD.md` §1.

#	Ferramenta	Classe	Página 1	Página 2	Alucinações	<i>Hands-on?</i>
1	Power Automate + AI Builder	Workflow comercial M365 + OCR treinado	100%	layout-sensível¹	0	✓ ponta a ponta
2	ChatGPT 5.5 Thinking	LLM <i>frontier</i>	100%	100%	0	✓
3	Claude Opus 4.7	LLM <i>frontier</i>	100%	100%	0	✓

4	NotebookLM (Gemini)	LLM ancorado em fontes	100%	100%	0	✓
5	Azure Document Intelligence Layout	OCR comercial estruturado	100% (16 células)	estrutura detectada ²	0	✓
6	Tabula (tabula-py 2.10)	OSS determinístico	100% (16 células)	0% ³	0	✓
7	Microsoft Copilot	LLM em invólucro M365	proxy de #2 ⁴	—	—	» dossiê
8	Make (Integromat)	iPaaS comercial	dossiê	dossiê	—	—
9	n8n	Workflow OSS	dossiê	dossiê	—	—

Notas: ¹ falha de fora-da-distribuição detalhada em §3. ² Azure DI Layout retorna texto + tabelas + parágrafos da página 2 corretamente, mas não estrutura automaticamente os parágrafos em JSON chave-valor; serve como componente para uma camada LLM acima. ³ Tabula não possui OCR, e a página 2 dos dossiês é conteúdo imagem. ⁴ Copilot é proxy da família OpenAI; o resultado do ChatGPT captura o comportamento sem informação marginal.

Identificamos também — durante a sondagem de mercado em pesquisa externa — o **Azure Document Intelligence**, ferramenta não citada no brief original e que se mostrou determinante para a camada 2 da arquitetura final. Detalhamos seu papel arquitetural em §4.

§2 — O que funcionou em cada uma

Pipeline de referência em Python (a solução que construímos). Implementamos a arquitetura híbrida recomendada em `06_reference_script/` (Azure DI Layout + Claude Sonnet 4.6 com *cross-validation* e trilha de auditoria). Medimos **100% de acurácia, zero alucinações e US\$ 0,00934 por dossiê** em quatro PDFs: o do brief, F02 (missing-email), F07 (skewed page 2) e o *holdout* OOD F09_brief_shape — estrutura visualmente fiel ao brief, com dados de cliente completamente novos (Salvador/BA, financiamento de veículo). O *holdout* é metodologicamente importante: teste cego do *prompt* contra a estrutura real-shape do brief. Durante o desenvolvimento corrigimos uma falha de interpretação semântica no *prompt* (extração de valores compostos) com uma regra explícita de **extração literal**; o *holdout* F09 foi rodado já sob o *prompt* corrigido, sem ajustes posteriores. Detalhes e *history note* em `06_reference_script/notes.md`.

LLMs frontier (ChatGPT, Claude, NotebookLM). As três ferramentas extraíram corretamente os 32 campos do PDF de exemplo (página 1 + página 2), com zero alucinações em validação contra `01_field_map/gold_truth.json`. As latências medidas foram 11,8 s (ChatGPT), 10,46 s (Claude) e 22,23 s (NotebookLM); todas para *upload* + chat UI, incluindo renderização — via API, esperamos 2–4 s. A convergência de três LLMs independentes no mesmo PDF é um sinal forte de *cross-validation* para casos limpos.

Power Automate + AI Builder. O fluxo *Revelatio Debtor Extraction* obteve **92,8% médio no corpus sintético** (132 células avaliadas em F01, F02, F05, F06) com **zero alucinações**: em F02 (e-mail ausente) e F03 (telefone ausente), o AI Builder devolveu campos vazios em vez de inventar valores. A trilha de auditoria nativa do Power Automate atende ao Art. 6º X da LGPD (responsabilização) sem código adicional. Detalhes em `04_experiments/02_power_automate/notes.md`.

Componentes determinísticos e OCR. O Azure DI Layout reconheceu a estrutura de ambas as páginas (16 células de tabela na página 1, parágrafos identificados na página 2 do PDF de exemplo) sem qualquer treinamento prévio — comportamento *layout-tolerant* exatamente no ponto em que o AI Builder falha (04_experiments/06_azure_di/notes.md). O Tabula extrai 100% da página 1 a custo zero, latência de 0,71–1,79 s por dossiê (04_experiments/07_tabula/notes.md).

§3 — O que não funcionou

Antes de listar falhas específicas, é honesto declarar a principal limitação metodológica: **nosso corpus sintético compartilha rótulos de campo com os dossiês reais do Banco X, mas a única validação contra layout fiel ao PDF do brief foi a do *holdout* F09 que geramos nós mesmos** — não temos acesso a dossiês reais do Banco X. O F09 reduz materialmente o risco de surpresa em produção (estrutura visualmente idêntica ao brief, dados novos, 100% de acerto), mas não substitui validação sobre o conjunto real (ver 04_experiments/SCOREBOARD.md §5 finding #2).

Falha 1 — AI Builder *layout-sensitive* na página 2. No PDF do brief, quatro campos da página 2 retornaram texto de rodapé como valor (por exemplo, "*Documento fictício para teste técnico*" como *proof_reference*). O AI Builder pratica *template matching* sobre a distribuição de treino; a página 2 do exemplo está fora dela. Mitigação: somar uma camada *layout-tolerant* (Azure DI + LLM) — incorporada por padrão no caminho principal Python, ainda a adicionar como *connector* HTTP no caminho M365. Diagnóstico em 04_experiments/02_power_automate/notes.md Fase 1.5.

Falha 2 — Tabula não possui OCR. 100% na página 1, **0% na página 2** (conteúdo imagem). Exclui-o como solução *standalone*, mantém-no como componente atraente na camada 1.

Falha 3 — Erro de *parse* de data na fronteira Power Automate → Excel. 12/02/2024 (12 de fevereiro BR) gravado como 2024-12-02 (2 de dezembro). Bug operacional do *connector* Excel, não do AI Builder. *Production-blocking* para deploy BR sem ajuste regional do *tenant*.

Cada falha é uma restrição de projeto: a primeira justifica a camada 2 (já inclusa no caminho principal); a segunda justifica Tabula como componente; a terceira justifica a fila HITL como rede de proteção.

§4 — Qual ferramenta faz mais sentido para o caso

Recomendamos uma **arquitetura híbrida em duas camadas** — não uma ferramenta única. A página 1 é estruturada e tem camada de texto extraível; a página 2 é imagem com layout variável. Tratar as duas com o mesmo motor é a origem das falhas em §3. A implementação que **construímos e validamos empiricamente** é o pipeline em 06_reference_script/ — esse é o caminho principal. O caminho M365 com Power Automate é alternativa legítima, com a ressalva de que a camada 2 ainda precisa ser adicionada ao fluxo PA antes do *cutover*.

Papel	Ferramenta recomendada	Justificativa empírica
Motor de extração e <i>cross-validation</i> (camada 1 + camada 2 + gate)	Pipeline Python em 06_reference_script/	100% em 4 PDFs (corpus de base + <i>holdout</i> OOD), 0 alucinações, US\$ 0,00934/dossiê

OCR + estrutura da página 2 (ambos caminhos)	Azure DI Layout	<i>Layout-tolerant</i> onde AI Builder falha; reconheceu parágrafos do PDF de exemplo sem treino
Mapeamento campo-a-campo na página 2	Claude API (Sonnet 4.6)	100% no PDF de exemplo + <i>holdout</i> OOD; <i>prompt</i> Opção-B com extração literal
<i>Cross-validator</i>	Regra de consistência de nome entre páginas (Titular do comprovante de endereço e Pagador do comprovante bancário devem corresponder ao nome da página 1)	Sem essa camada, página 1 correta permite página 2 <i>garbage</i> (Fase 1.5 finding #5). CPF é passado como contexto ao <i>prompt</i> mas não há CPF na página 2 para comparar
Extrator página 1 do caminho M365 (alternativo)	AI Builder Custom Extraction	92,8% sintético com 0 alucinações no corpus F01–F06
Orquestrador do caminho principal (a escolher)	n8n auto-hospedado, <i>cron</i> + pasta monitorada, ou <i>trigger</i> HTTP de aplicação web	Qualquer opção viável; n8n foi avaliado em dossiê (02_tool_universe/05_n8n.md) mas não construído no PoC. O motor foi orquestrado via CLI em <code>extract_dossier.py</code>
Orquestrador caminho M365 alternativo	Power Automate	Trilha de auditoria nativa, manutenção por paralegal

A introdução do Azure DI Layout — ferramenta não listada no brief — é estrutural à recomendação: é o único componente testado que combina *layout-tolerance* com custo previsível (US\$ 1,50 por 1.000 páginas, ~US\$ 30 para o backlog inteiro). Sem ele, nenhum dos dois caminhos tem rota honesta para sair da falha *layout-sensitive* descrita em §3.

A síntese consolidada está em 04_experiments/SCOREBOARD.md §3 e §6; os diagramas formais da arquitetura estão em 07_architecture/diagrams.md.

§5 — Como essa ferramenta seria utilizada no fluxo da equipe

A arquitetura existe em duas implementações paralelas, escolhidas conforme o perfil tecnológico do escritório. O ciclo HITL é compartilhado.

Caminho principal — motor Python de referência (construído, validado e publicamente acessível). O componente central é o pipeline em 06_reference_script/, que implementa as duas camadas com *cross-validation* de nome entre páginas e trilha de auditoria, validado nos 4 PDFs descritos em §2. O motor é exposto via **interface web hospedada em <https://revelatio-demo.streamlit.app>** (Streamlit Community Cloud) que aceita upload de PDFs e oferece gravação automática em planilha Google compartilhada com o painel como destino opcional — código em 06_reference_script/app.py + 06_reference_script/sheets_writer.py, runbook de deploy em DEPLOY.md na raiz do repositório. O `extract_dossier.py` permanece como entrada CLI alternativa para uso *headless*. Para *batch* em produção sobre o backlog de 10k dossiês, a camada de orquestração fica a critério do escritório — opções viáveis incluem **n8n auto-hospedado** (escolha

natural pelo perfil OSS + auditável, e a única dessas opções que avaliamos em dossiê), *cron* com pasta monitorada, ou *trigger* HTTP de uma aplicação web já existente; não construímos nenhuma delas no PoC. Referências: 02_tool_universe/05_n8n.md e Diagrama 2 de 07_architecture/diagrams.md.

Caminho alternativo — M365 com Power Automate (escritórios já residentes em Microsoft 365). Fluxo disparado pela chegada do PDF no SharePoint: AI Builder na página 1, Azure DI Layout + Claude API sobre a página 2 em casos de baixa confiança, *cross-validation* de nome entre páginas (Titular e Pagador da página 2 batem com o cliente da página 1), gravação em *dossiers.xlsx* (ou fila HITL). A camada da página 1 está construída e validada em Epic 5.2 (92,8% sintético, 0 alucinações); a camada da página 2 é especificada arquiteturalmente, deve ser adicionada como *connector* HTTP ao fluxo PA antes do *cutover* de produção. Vantagem operacional: manutenção *no-code* por paralegal. *Reference*: Diagrama 1 em 07_architecture/diagrams.md.

Ciclo HITL e *cross-validation*. Quando uma linha falha na *cross-validation* (CPF da página 2 não bate com o da página 1, por exemplo), o sistema marca `needs_review = TRUE` e roteia a linha para uma fila. A paralegal abre a linha — apenas os campos sinalizados precisam de revisão, com os demais já pré-preenchidos — e aprova, corrige ou rejeita. Cada ação gera registro em *audit.csv* com carimbo de tempo e identificador da revisora. Esse desenho está em 07_architecture/diagrams.md §4.

Rubrica de escolha do caminho. Três entradas binárias (tem licenças M365? tem capacidade de desenvolvimento? tem ≥30 dossiês reais para treino?) determinam o caminho recomendado. Detalhe em 07_architecture/diagrams.md §5. Escritórios sem M365 e sem capacidade técnica interna precisam de parceiro externo de implementação — o relatório é explícito quanto a isso, não há versão honesta da arquitetura que se opere sozinha nesse cenário.

§6 — Possíveis limitações ou cuidados da solução

LGPD — enquadramento e base legal. A base legal primária é o **Art. 7º, V** (execução de contrato e procedimentos preliminares de cobrança); a base secundária é o **Art. 7º, IX** (legítimo interesse). O sistema é deliberadamente desenhado como **preparação de dados**, não decisão automatizada — toda decisão consequente (estratégia de cobrança, execução fiscal, oferta de acordo) é tomada por advogado a jusante da planilha. Esse enquadramento mantém o projeto fora da obrigação de revisão sob o **Art. 20**, condicionado à existência efetiva da camada HITL (07_architecture/lgpd.md §10). Os termos de uso da Anthropic (anthropic.com/legal/commercial-terms §B) e a documentação de privacidade do Azure Document Intelligence (verificados em 2026-05-11) confirmam que o conteúdo enviado via API não é usado para treinamento.

Limitações metodológicas. Três restrições: (i) o *holdout* F09 valida estrutura visualmente fiel ao brief, mas **ainda não testamos contra dossiês reais do Banco X**; (ii) $n=1$ sobre o PDF do brief; (iii) o Azure DI Custom Neural **não foi treinado** (requer 30+ dossiês reais). Consolidação em 04_experiments/SCOREBOARD.md §5.

§7 — Possível plano inicial de implementação

Propomos um plano em três fases, ancorado nos números empíricos das seções anteriores.

Fase 1 — Provisionamento e *baseline* de dados (semanas 1–2). Migração para Brasil Sul (M365 e Azure DI, se aplicável); assinatura do DPA da Anthropic; primeira versão do RIPD pelo DPO; coleta dos 30 dossiês reais para treino futuro do Custom Neural ou AI Builder. *Setup* do caminho principal: 2–3 dias de engenharia para escolher e integrar uma camada de orquestração (n8n, *cron* + pasta monitorada ou *trigger* HTTP) sobre o motor já validado, e configurar UI HITL com SSO. *Setup* do caminho alternativo M365: 1–2 dias para adicionar a *branch* de *fallback* da página 2 (Azure DI + Claude) ao fluxo Power Automate existente.

Fase 2 — Piloto sobre o backlog (semanas 3–4). Processamento dos 10.000 dossiês com a fila HITL ativa e a regra de *cross-validation* armada. Custo previsto de API: **R\$ 457** (US\$ 93,37 ao PTAX 4,8999, *venda* de 2026-05-08, fonte BCB Olinda). Tempo de relógio estimado em 3–6 horas com concorrência de 5–10 chamadas simultâneas, conforme item #2 do *checklist* em 06_reference_script/notes.md. Comparativo da extração manual sobre o mesmo volume: **R\$ 50.500** (10.000 × 6 min 44 s × R\$ 45/h no ponto médio), com base na medição empírica n=1 em 07_architecture/manual_timing.md. *Payback*: dia um. Razão **~110×**.

Fase 3 — Endurecimento de produção (semanas 5–8). Implementação do *checklist* de oito itens em 06_reference_script/notes.md — *retry* com *backoff*, limitação de taxa, idempotência por *hash*, monitoramento de custo com alerta de teto, SSO no UI HITL, redação de CPFs em *audit.csv*, chamada explícita de *Delete Analyze Result* no Azure DI, *runbook* de incidentes. Treino do Custom Neural quando os 30 dossiês reais da Fase 1 estiverem rotulados; expectativa de redução marginal do custo de Claude na página 2.

A tabela abaixo, condensada de 07_architecture/roi.md §5, mostra que a recomendação permanece robusta sob variação plausível de volume e taxa HITL.

Volume anual	5% HITL	10% HITL	20% HITL	Manual no ponto médio
1.000	R\$ 118	R\$ 193	R\$ 343	R\$ 5.050
10.000	R\$ 1.184	R\$ 1.934	R\$ 3.434	R\$ 50.500
100.000	R\$ 11.843	R\$ 19.343	R\$ 34.343	R\$ 505.000

Em qualquer linha, a razão automatizado/manual permanece acima de 10×, o que torna a conclusão de viabilidade econômica insensível a estimativas pessimistas. **O script Python que executa a Fase 2 já existe e está disponível no *bundle* em 06_reference_script/**, com README de execução, *test corpus* validado e o gerador do *holdout* OOD (05_synthetic_data/generate_brief_shaped_ood.py) reprodutível.

Documentos de apoio (anexos do bundle): 06_reference_script/ (script Python + audit log + *history note* da extração literal); 05_synthetic_data/ (gerador, PDFs e *gold* do *holdout* F09); 04_experiments/SCOREBOARD.md (síntese empírica); 07_architecture/ (diagrams, roi, lgpd, manual_timing); decisions.md (ADR D-006).